

Dataset open data europei e italiani per una dashboard Streamlit di Data Visualization

TL;DR

- Per un progetto Streamlit con taglio automotive/mobilità/energia, i tre dataset più adatti per qualità, dimensione gestibile e ricchezza di variabili sono: **ACI Open Data - parco veicolare/immatricolazioni** (via dati.gov.it / aci.gov.it, CSV "livello 5"), **Incidenti stradali di Roma Capitale** (dati.comune.roma.it, CSV mensili con coordinate WGS84) e **Terna - sistema elettrico italiano** (dati.terna.it, CSV con export diretto).
- Per dataset paneuropei in inglese e facili da mappare/confrontare, i migliori sono **EEA - Monitoring of CO2 emissions from passenger cars** (ricchissimo di variabili tecniche, ma da campionare perché enorme), **Eurostat road_eqs** (parco auto per alimentazione/Paese, ideale per confronti UE) e i punti di ricarica di **data.gouv.fr (IRVE)**.
- Evitare per un primo progetto: il parco circolante MIT (oltre 51 milioni di veicoli in ZIP), ERA5/Copernicus (NetCDF/GRIB, non tabellare) e i flussi orari grezzi di ARPA/Bologna/Milano se non si è disposti a fare downsampling/aggregazione.

Key Findings

Ho privilegiato fonti istituzionali con licenze aperte (CC-BY, IODL 2.0, Licence Ouverte) e formati tabellari (CSV/JSON). Distinguo nettamente i dataset "pronti per Streamlit" (dimensione gestibile, mix di variabili numeriche/categoriche/temporali/geografiche) da quelli potenzialmente troppo grandi o in formati ostici (SDMX, NetCDF, ZIP da milioni di righe). La maggior parte dei portali italiani regionali/comunali usa CKAN o Socrata/OpenDataSoft, con API e download CSV diretti; Eurostat e ISTAT espongono nativamente SDMX, che richiede attenzione. La regola pratica adottata: un dataset è un candidato ideale se sta tra ~500 e ~50.000 righe in CSV/JSON; se supera ~100k righe o non è tabellare va pre-elaborato offline o scartato per la prima iterazione.

Details

1. ACI Open Data - Parco veicolare e immatricolazioni (Italia)

- **Link:** portale ACI Linked Open Data <http://lod.aci.it/> ; sezione open data istituzionale <https://aci.gov.it/attivita-e-progetti/studi-e-ricerche/open-data/> ; mirror tematici su dati.gov.it (es. "Veicoli circolanti suddivisi per anno di immatricolazione").
- **Contenuto:** serie storiche nazionali, regionali, provinciali e comunali su parco veicolare, prime iscrizioni, radiazioni, trasferimenti di proprietà; classificazioni per categoria, alimentazione, classe Euro, cilindrata, anno di immatricolazione, fabbrica. Fonte primaria: Pubblico Registro Automobilistico (PRA).
- **Dimensione/formato:** CSV e RDF; i singoli tagli tematici (es. veicoli per regione/anno/alimentazione) sono tipicamente da poche centinaia a qualche decina di

migliaia di righe — perfetti per Streamlit. Il portale è classificato "open data di livello 5" (la classificazione massima di Tim Berners-Lee), con licenza CC-BY 4.0.

- **Variabili:** categoriche (categoria veicolo, alimentazione, classe Euro, marca), numeriche (conteggi, cilindrata, potenza), temporali (anno/mese), geografiche (regione/provincia/comune).
- **Visualizzazioni Streamlit:** serie storiche immatricolazioni; stacked bar per alimentazione/classe Euro; mappe coropletiche per regione/provincia; confronto diesel vs benzina vs elettrico nel tempo.
- **Criticità:** alcune risorse RDF non servono al progetto; i ritagli più granulari (comune) possono diventare grandi; attenzione all'omogeneità degli schemi tra annualità.

2. Incidenti stradali nel territorio di Roma Capitale

- **Link:** dataset annuali su Open Data Roma, es. Anno 2022
<https://dati.comune.roma.it/catalog/dataset/d108> e Anno 2021
<https://dati.comune.roma.it/catalog/dataset/d106> (serie disponibile dal 2007 al 2022).
- **Contenuto:** tutti gli incidenti stradali rilevati dalla Polizia Locale di Roma Capitale (esclusi quelli conciliati e quelli sul GRA), con dettaglio di incidente, veicoli, persone e pedoni coinvolti. Comune Comune
- **Dimensione/formato:** pubblicato come risorse **mensili** in CSV, JSON e XML, per quattro entità (incidenti, veicoli, persone, pedoni). Secondo il Rapporto ACI-ISTAT 2022 (ANSA, 13/10/2023), "nel 2022 sulle strade di Roma si sono registrati 13.181 incidenti (11.129 nel 2021, 8.229 nel 2020 e 12.271 nel 2019) con 16.618 feriti (13.862 nel 2021) e 150 vittime (121 nel 2021)" — Roma è il primo comune italiano per incidenti e vittime. Una volta concatenati i mesi si ottengono quindi dataset gestibili (~11k-13k incidenti/anno a livello di evento). Coordinate in WGS84. Comune
- **Variabili** (nomi di campo verbatim dal dump CKAN): Protocollo, Gruppo, DataOraIncidente, Localizzazione1, STRADA1, NaturaIncidente, TipoStrada, FondoStradale, CondizioneAtmosferica, Traffico, Visibilita, Illuminazione, NUM_FERITI, NUM_MORTI, NUM_ILLESI, Longitudine, Latitudine, e per veicoli/persone TipoVeicolo, StatoVeicolo, TipoPersona, Sesso, Tipolesione, Deceduto, CinturaCascoUtilizzato, Airbag.
- **Visualizzazioni Streamlit:** mappa puntuale degli incidenti (lat/long pronti); heatmap per ora/giorno della settimana; barre per natura incidente e condizioni atmosferiche; trend mensile feriti/morti.
- **Criticità:** download per mese (serve concatenazione); il 2022 risulta parziale (ultimo mese disponibile agosto, per manutenzione del sistema Polizia Locale); join tra le tabelle incidenti/veicoli/persone via Protocollo; la licenza non è leggibile via fetch automatico ma il portale Open Data Roma usa tipicamente IODL 2.0 / CC-BY (da confermare nel box metadati della pagina). Comune

3. Terna - Dati sul sistema elettrico italiano

- **Link:** <https://dati.terna.it/en/> con sezioni Load (fabbisogno), Generation (produzione per

fonte), Transmission, Market; Download Center <https://dati.terna.it/en/download-center>.

- **Contenuto:** domanda elettrica nazionale e per zona di mercato; produzione per fonte (termico, idro, eolico, fotovoltaico, geotermico, biomasse); capacità installata; bilancio energetico; scambi. (Terna) (Terna)
- **Dimensione/formato:** export CSV/Excel direttamente dai grafici. Il portale dichiara dati "from 2000 to today"; per alcuni parametri (tra cui l'energia elettrica richiesta) la pubblicazione annuale "Dati statistici sull'energia elettrica in Italia" riporta la serie storica annuale addirittura dal 1883. Numeri in formato inglese (punto decimale). Aggregando a livello mensile/giornaliero si ottengono serie di dimensione contenuta; i dati orari/quartorari sono più voluminosi.
- **Variabili:** temporali (timestamp, mese, anno), numeriche (MWh, MW), categoriche — in particolare le zone di mercato confermate verbatim dal JSON del Download Center: North, Centre-North, Centre-South, South, Sardinia, Sicily, Calabria, Italy.
- **Visualizzazioni Streamlit:** time series del fabbisogno; area chart del mix di generazione per fonte; confronto rinnovabili vs fossili; analisi stagionale/giornaliera della domanda; mappa per zona di mercato.
- **Criticità:** dati provvisori soggetti a revisione; per le serie ad alta frequenza occorre aggregare; l'API richiede token (ma il Download Center no).

4. EEA - Monitoring of CO2 emissions from passenger cars (Regulation EU 2019/631)

- **Link:** <https://www.eea.europa.eu/en/datahub/datahubitem-view/fa8b1229-3db6-495d-b18e-9c9b3267c02b>; esploratore <https://co2cars.apps.eea.europa.eu/>
- **Contenuto:** una riga per modello/variante di auto nuova immatricolata nell'UE, con dati tecnici e di emissione, raccolti per ogni Stato membro (EU-27 + Islanda + Norvegia).
- **Dimensione/formato:** CSV (.csv/.txt/.sql), anche endpoint SQL (Discodata). È enorme: l'archivio parte dal 2012 e ha superato i **37 milioni di righe e oltre 8 GB** di dati (rif. repository GitHub gpinvestigativ/EEA-CO2-emissions-passenger-cars; citazione: EEA, "Monitoring of CO2 Emissions from Passenger Cars, 2024 Provisional Dataset", 4 giugno 2025). Come riferimento di scala, il solo archivio CSV 2012 (CO2_passenger_cars_v13_csv.zip) pesa 7,74 MB compresso. Per Streamlit va campionato/filtrato (un Paese, un anno) o pre-aggregato. (European Environment Ag...)
- **Variabili:** numeriche (CO2 WLTP/NEDC, massa, passo, carreggiata, cilindrata, potenza, consumo elettrico), categoriche (costruttore, marca, nome commerciale, tipo di carburante, modo di alimentazione), geografiche (Paese), temporali (anno).
- **Visualizzazioni Streamlit:** scatter massa vs CO2; trend CO2 medie per anno; box plot per carburante; confronto tra costruttori; mappa per Paese.
- **Criticità:** dimensione — scaricare l'intero archivio (8+ GB) appesantirebbe la dashboard, quindi è obbligatorio filtrare/aggregare prima; lo schema delle colonne non è coerente tra le annate (vanno mappate le colonne, in particolare quelle delle emissioni).

5. Eurostat - road_eqs (parco auto per alimentazione, motore, abitanti)

- **Link:** data browser, es. (road_eqs_carpda) (passenger cars by type of motor energy)

[https://ec.europa.eu/eurostat/databrowser/view/road_eqs_carpda/default/table?lang=en;](https://ec.europa.eu/eurostat/databrowser/view/road_eqs_carpda/default/table?lang=en;road_eqs_carhab)
([road_eqs_carhab](#)) (auto per mille abitanti); database trasporti
<https://ec.europa.eu/eurostat/web/transport/database>.

- **Contenuto:** stock e tasso di motorizzazione delle auto per Paese UE, per tipo di alimentazione e dimensione del motore.
- **Dimensione/formato:** scaricabile in CSV/TSV/JSON; dimensioni contenute (Paesi × anni × categorie = qualche migliaio di righe).
- **Variabili:** categoriche (Paese; classe cilindrata; tipo di alimentazione, code list ufficiale [mot_nrg]: ALT = energia alternativa, DIE = diesel, ELC = elettrico, ELC_PET_PI = ibrido plug-in benzina-elettrico, GAS = gas naturale, HYD_FCELL = idrogeno/fuel cell, LPG, PET = prodotti petroliferi, TOTAL), numeriche (numero di veicoli, per mille abitanti), temporali (anno). Esempio di insight: secondo Eurostat ("Passenger cars in the EU"), in Italia la quota di auto a combustibili alternativi nel parco circolante ha raggiunto il 10,6% nel 2024.
- **Visualizzazioni Streamlit:** mappa coropleetica del tasso di motorizzazione UE; confronto quota EV/diesel/benzina per Paese; trend pluriennale.
- **Criticità:** l'estrazione nativa Eurostat è in SDMX; conviene usare il bulk download CSV o l'estrazione "full" dal data browser; i codici dimensione sono poco leggibili (servono le code list).

6. data.gouv.fr – Base nationale des IRVE (punti di ricarica EV in Francia)

- **Link:** <https://transport.data.gouv.fr/datasets/fichier-consolide-des-bornes-de-recharge-pour-vehicules-electriques>
- **Contenuto:** file consolidato nazionale dei punti di ricarica per veicoli elettrici, con localizzazione e caratteristiche tecniche.
- **Dimensione/formato:** CSV e GeoJSON; pubblicato sotto "Licence Ouverte / Open Licence". Attenzione alla semantica: il file elenca **punti di ricarica** (campo [id_pdc_itinerance](#)), non stazioni/colonnine — la documentazione Etalab avverte che dal file non è possibile dedurre il numero di colonnine. L'ordine di grandezza è comunque di decine di migliaia di righe, gestibile.
- **Variabili:** geografiche (lat/long, indirizzo), categoriche (operatore, tipo di presa, accessibilità), numeriche (potenza kW).
- **Visualizzazioni Streamlit:** mappa dei punti di ricarica; istogramma per potenza; barre per operatore; confronto per regione.
- **Criticità:** dataset noto per problemi di integrità/duplicati (esistono file di correzione pubblicati); campi in francese.

7. ARPA Lombardia – Dati sensori aria (qualità dell'aria)

- **Link:** portale Socrata Open Data Regione Lombardia, dataset corrente <https://www.dati.lombardia.it/Ambiente/Dati-sensori-aria/nicp-bhqi> e archivi annuali (es.

"Dati sensori aria dal 2018"); anagrafica stazioni

<https://www.dati.lombardia.it/Ambiente/Stazioni-qualit-dell-aria/ib47-atvt>

- **Contenuto:** misure in continuo degli inquinanti (NOX, SO2, CO, O3, PM10, PM2.5, benzene) dalle stazioni fisse ARPA; frequenza oraria (media giornaliera per PM10/PM2.5).
(Open Data Network)
- **Dimensione/formato:** CSV/JSON via Socrata con API SODA (filtri, aggregazioni); i file annuali grezzi sono molto grandi (milioni di righe), ma l'API consente di scaricare sottoinsiemi.
- **Variabili:** temporali (data/ora), numeriche (valore inquinante), categoriche/geografiche (id sensore, stazione → join con anagrafica per lat/long, tipo inquinante).
- **Visualizzazioni Streamlit:** serie temporali PM10/PM2.5 per stazione; mappa delle stazioni con valore medio; confronto stagionale; superamenti soglia.
- **Criticità:** dati "long" da pivotare; volume elevato (filtrare per stazione/periodo via API); join con anagrafica stazioni per le coordinate.

8. Comune di Bologna – Rilevazione flusso veicoli tramite spire

- **Link:** <https://opendata.comune.bologna.it/explore/dataset/rilevazione-flusso-veicoli-tramite-spire-anno-2024/> (serie dal 2019); dataset complementare "Accuratezza spire"; piattaforma OpenDataSoft con export.
- **Contenuto:** conteggio orario dei veicoli transitati su ogni spira induttiva della città, con posizione geografica e indicatore di accuratezza.
- **Dimensione/formato:** CSV/JSON/GeoJSON via OpenDataSoft; dato orario per centinaia di spire per un anno → milioni di righe (grande, ma filtrabile/aggregabile via API e faccette).
- **Variabili:** temporali (data, ora), numeriche (conteggio veicoli, accuratezza %), geografiche (coordinate spira, codice/(id_uni)), categoriche (livello, direzione).
- **Visualizzazioni Streamlit:** heatmap traffico per ora/giorno; mappa delle spire; trend annuale; confronto pre/post interventi.
- **Criticità:** volume elevato (aggregare a giorno/settimana); il codice spira cambia nel tempo (usare (id_uni)/(ID_univoco_stazione_spira)); filtrare per accuratezza.

Altri portali e dataset segnalati (con cautele)

- **MIT - Parco circolante dei veicoli** (<https://dati.mit.gov.it/catalog/dataset/dataset-parco-circolante-dei-veicoli>): contiene i dati tecnici di oltre 51 milioni di veicoli (~44,3 mln autoveicoli + ~7,1 mln motoveicoli) con marca, cilindrata, massa, alimentazione, CO2, classe Euro. Ricchissimo ma pubblicato in ZIP per la mole enorme: **inadatto al caricamento diretto in Streamlit** senza pre-elaborazione/campionamento. (Mit)
- **ISTAT (dati.istat.it / esploradati.istat.it)** – incidenti stradali (dataflow 41_983 "Incidenti, morti e feriti - comuni"), veicoli PRA, trasporto ferroviario: ottimi contenuti ma esposti in SDMX; esiste l'API REST e l'export CSV, ma i file completi possono pesare centinaia di MB (l'XML completo degli incidenti è ~53 MB). Usare filtri ((lastNobservations), chiavi

dimensione). Riferimento pratico: la guida ondata alle API REST ISTAT (<https://ondata.github.io/guida-api-istat/>).

- **aperTO – Comune di Torino** (<https://aperto.comune.torino.it/dataset>): flussi di traffico, ZTL, car sharing, colonnine di ricarica, GTFS. Molti dataset puntuali/geografici (CSV, SHP, GeoJSON, JSON) di dimensione contenuta, ottimi per mappe; licenza IODL v2.0.
- **Copernicus Climate Data Store – ERA5** (<https://cds.climate.copernicus.eu/>): dati climatici globali ricchissimi (dal 1940/1950) ma in **NetCDF/GRIB**, non tabellari: richiede librerie dedicate (xarray/cdsapi) e registrazione — sconsigliato per un primo progetto Streamlit, a meno di usare gli aggregati giornalieri/mensili.
- **European Alternative Fuels Observatory (EAFO)** (<https://alternative-fuels-observatory.ec.europa.eu/>): statistiche su veicoli a combustibili alternativi e infrastruttura di ricarica per Paese, scaricabili in Excel; dimensioni piccole, buone per confronti UE (es. dataset HDV recharging per Paese).
- **data.europa.eu**: aggrega molti dei dataset sopra (incluso un mirror degli incidenti di Roma) ed è utile come punto di scoperta unico.

Recommendations

1. **Parti da un dataset "core" gestibile e ricco di variabili**: la scelta migliore per il profilo (automotive + ingegneria) è la combinazione **ACI parco veicolare/immatricolazioni** (confronti categorici e temporali) + **Incidenti Roma Capitale** (per la componente geospaziale con mappe). Entrambi sono CSV, di dimensione gestibile una volta aggregati/concattenati.
2. **Aggiungi un layer energia/tech**: integra **Terna** (mix di generazione e domanda) per serie temporali pulite e d'impatto, oppure **Eurostat road_eqs** per un confronto europeo del parco auto per alimentazione (con la code list [mot_nrg] per etichette leggibili).
3. **Per le mappe puntuali** usa Roma incidenti (lat/long già presenti) o IRVE Francia / colonnine Torino.
4. **Workflow tecnico**: scarica i CSV una volta, salvali localmente o in cache (`@st.cache_data`), pre-aggrega i dataset grandi (ARPA, Bologna spire, EEA CO2) prima di caricarli; non leggere file da decine di milioni di righe a runtime.
5. **Soglie decisionali**: se un file supera ~100k righe o non è in CSV/JSON tabellare (SDMX, NetCDF, ZIP multi-milione), pre-elaboralo offline o scartalo per questa iterazione. Se invece è 500-50.000 righe in CSV con mix di variabili numeriche/categoriche/temporali/geografiche, è un candidato ideale.
6. **Verifica licenza e schema** prima di costruire: conferma CC-BY/IODL/Licence Ouverte e controlla la coerenza delle colonne tra annate (ACI ed EEA cambiano schema nel tempo).

Caveats

- Alcune dimensioni in righe/colonne sono stime basate sulle descrizioni dei portali: vanno verificate scaricando un campione, perché molti portali non dichiarano il conteggio esatto dei record.

- Diversi dataset italiani sono in italiano (nomi colonne inclusi); i paneuropei (EEA, Eurostat, EAFO) e francesi (IRVE) sono in inglese/francese.
- I dati Terna e ARPA sono "provvisori" o soggetti a revisione/manutenzione; il dataset incidenti di Roma 2022 è parziale (fino ad agosto).
- Eurostat e ISTAT privilegiano SDMX: usabili ma con curva di apprendimento; preferire bulk CSV o API REST con filtri.
- La licenza esatta del dataset incidenti di Roma non è stata letta verbatim (pagina bloccata al fetch automatico): va confermata sulla pagina. Copernicus/ERA5 e il parco circolante MIT sono citati per completezza ma sono sconsigliati per una prima dashboard Streamlit per formato/volume.