

Dataset pubblici per un progetto di Data Visualization con Streamlit

TL;DR

- I tre dataset più adatti al tuo profilo (ingegneria informatica + meccanica) sono **CO2 Emission by Vehicles** (Kaggle, 7.385 righe × 12 colonne, mix perfetto numerico/categorico), **Electric Vehicle Population Data - Washington** (≈200.000+ righe, 17 colonne, fortissima componente geografica per le mappe) e **Bike Sharing Dataset** (UCI, 17.379 righe orarie, ottima dimensione temporale): tutti scaricabili gratuitamente in CSV e ideali per una dashboard Streamlit con barchart, scatter, istogrammi e mappe.
- Per i dati italiani richiesti (ISTAT/dati.gov.it) i migliori sono **Incidenti stradali del Comune di Milano 2001-2024** (serie temporale mensile, scaricabile in CSV) e i dati di **Terna sulla generazione elettrica** (dimensione temporale + per fonte energetica), entrambi tecnici ma accessibili.
- Per i tuoi interessi specifici aggiungo **Formula 1 World Championship 1950-2024** (Kaggle, motorsport/meccanica) e **Stack Overflow Developer Survey** (tech/mercato del lavoro IT); evita dataset oltre ~100.000 righe (es. US Used Cars, con milioni di record) che renderebbero lenta la dashboard.

Key Findings

Otto dataset concreti, tutti liberamente scaricabili, ordinati per adattabilità al tuo progetto. I migliori per partire subito sono il **CO2 Emission by Vehicles** e il **Bike Sharing**, perché hanno dimensioni contenute, zero/minimi valori mancanti e un mix bilanciato di variabili numeriche, categoriche e (per il bike sharing) temporali. Se invece il punto di forza del tuo progetto devono essere le **mappe**, l'**Electric Vehicle Population Data** è la scelta migliore perché include coordinate geografiche già pronte all'uso.

Details

1. CO2 Emission by Vehicles (Kaggle) — CONSIGLIATO #1

- **Link:** <https://www.kaggle.com/datasets/debajyotipodder/co2-emission-by-vehicles>
- **Contenuto:** emissioni di CO2 e consumi di carburante per modelli di auto venduti in Canada, compilati dal portale open data del governo canadese su un periodo di 7 anni (circa modelli 2014-2020).
- **Dimensioni:** 7.385 righe × 12 colonne (cifra confermata da fonti multiple, inclusa la descrizione dell'autore e un articolo peer-reviewed su *Scientific Reports*, 2025); singolo file CSV di circa 88 KB.
- **Variabili:** numeriche (cilindrata motore in litri, numero cilindri, consumo urbano/extraurbano/combinato, CO2 g/km); categoriche (marca, modello, classe veicolo, tipo di trasmissione, tipo di carburante). Nessuna dimensione temporale o geografica esplicita.

- **Visualizzazioni:** scatter plot cilindrata vs CO2, istogrammi di emissioni, barchart per marca/classe, boxplot per tipo di carburante, heatmap di correlazione.
- **Perché è adatto:** dimensione perfetta, dati puliti, tema meccanico/automotive, mix numerico-categorico ideale per filtri Streamlit (selectbox su marca/carburante). È il dataset con il miglior rapporto semplicità/ricchezza per il tuo background ingegneristico-meccanico.

2. Electric Vehicle Population Data — Washington State — CONSIGLIATO #2

- **Link Kaggle:** <https://www.kaggle.com/datasets/usamabuttar/electric-vehicle-population-data-washington-us>
- **Link fonte ufficiale:** <https://data.wa.gov/Transportation/Electric-Vehicle-Population-Data/f6w7-q2d2>
- **Contenuto:** veicoli elettrici a batteria (BEV) e ibridi plug-in (PHEV) registrati presso il Department of Licensing dello Stato di Washington. (Kaggle)
- **Dimensioni:** dataset "live" aggiornato l'ultima volta il 13 maggio 2026 (Catalog Last Checked 18 maggio 2026, secondo catalog.data.gov), in costante crescita: a inizio 2024 si contavano ~170.000 EV registrati, di cui 91.379 Tesla (marca dominante), 15.419 Chevrolet e 14.721 Nissan, secondo l'analisi su dati DOL di ottobre 2024. Struttura: 17 colonne. Licenza Open Data Commons ODbL v1.0.
- **Variabili:** numeriche (model year, electric range, base MSRP); categoriche (make, model, EV type, CAFV eligibility, electric utility); geografiche (county, city, postal code, vehicle location come coordinate, 2020 census tract, legislative district).
- **Visualizzazioni:** mappa dei veicoli per contea/coordinate (st.map / pydeck), barchart per marca/modello, istogramma dell'autonomia elettrica, trend per anno di modello.
- **Perché è adatto:** è il dataset migliore se vuoi mostrare le mappe in Streamlit, perché contiene coordinate già pronte. Tema automotive/tech. Attenzione: filtra le colonne e usa caching per non rallentare la dashboard.

3. Bike Sharing Dataset (UCI) — CONSIGLIATO #3

- **Link:** <https://archive.ics.uci.edu/dataset/275/bike+sharing+dataset>
- **Contenuto:** conteggio orario e giornaliero dei noleggi di bici del sistema Capital Bikeshare (Washington DC) 2011-2012, con informazioni meteo e stagionali (autori Fanaee-T e Gama, *Progress in Artificial Intelligence*, 2013).
- **Dimensioni:** il file (hour.csv) contiene 17.379 record orari, il file (day.csv) 731 record giornalieri (confermato dal Readme.txt UCI: "hour.csv... Records: 17379 hours" e "day.csv... Records: 731 days"); 17 colonne. Licenza CC BY 4.0. (UCI Machine Learning Rep...)
- **Variabili:** numeriche (temp, umidità, velocità vento, conteggi casual/registered/totale); categoriche (stagione, mese, festività, giorno lavorativo, situazione meteo); temporali (data, ora, anno). (UCI Machine Learning Rep...)
- **Visualizzazioni:** serie temporale dei noleggi, barchart per ora del giorno, scatter temperatura vs noleggi, boxplot per stagione/mese, heatmap ora×giorno.

- **Perché è adatto:** dimensione temporale eccellente per slider e animazioni in Streamlit, dati puliti senza valori mancanti, tema mobilità urbana. Perfetto per imparare i grafici interattivi temporali. (Medium)

4. Formula 1 World Championship (1950-2024) (Kaggle)

- **Link:** <https://www.kaggle.com/datasets/rohanrao/formula-1-world-championship-1950-2020>
- **Contenuto:** dati completi su gare, piloti, costruttori, tempi sul giro, pit stop, qualifiche, classifiche; dati dal database Ergast, "gathered and published to the public domain by Chris Newell". Nota: l'API ergast.com/mrd è stata dismessa a fine 2024 e dal 2025 il dataset si aggiorna tramite l'API compatibile Jolpica (api.jolpi.ca).
- **Dimensioni:** multi-tabella (più CSV: results, races, drivers, constructors, lap_times, pit_stops, ecc.); la tabella più grande è `lap_times`, con oltre 500.000 righe (i dati lap-by-lap Ergast partono dal 1996), mentre le altre vanno da poche centinaia a decine di migliaia di righe.
- **Variabili:** numeriche (punti, posizioni, tempi, giri); categoriche (pilota, costruttore, nazionalità, circuito); temporali (anno, data gara); geografiche (località e coordinate dei circuiti nella tabella circuits).
- **Visualizzazioni:** evoluzione punti per pilota/stagione, mappa dei circuiti, barchart vittorie per costruttore, scatter posizione di partenza vs arrivo.
- **Perché è adatto:** tema motorsport ideale per il background meccanico; richiede però join tra tabelle (leggermente più complesso). Ottimo se vuoi mostrare capacità di data wrangling.

5. Incidenti stradali — Comune di Milano (2001-2024) — DATO ITALIANO

- **Link:** <https://dati.comune.milano.it/it/dataset/ds175-trafficotrasporti-incidenti-stradali-persone-infortunate-mese>
- **Contenuto:** dati mensili sugli incidenti stradali con lesioni a persone nel territorio del Comune di Milano (rilevati dalla Polizia Locale secondo indicazioni ISTAT), distinti per incidenti mortali/con feriti e numero infortunati.
- **Dimensioni:** serie temporale mensile dal 2001 al 2024 (qualche centinaio di righe); CSV scaricabile.
- **Variabili:** numeriche (numero incidenti, morti, feriti); temporali (mese, anno); categoriche (esito/tipologia).
- **Visualizzazioni:** serie temporale degli incidenti, barchart per anno, confronto mortali vs feriti, stagionalità mensile.
- **Perché è adatto:** dato italiano ufficiale e accessibile, tema sicurezza stradale/mobilità. Dimensione piccola: meglio combinarlo con altri o usarlo per dashboard semplici. In alternativa, per dati geografici a livello comunale, vedi gli Open Data del Comune di Bologna (https://opendata.comune.bologna.it/explore/dataset/incidenti_new/table/) o di Regione Lombardia.

6. Terna — Generazione e fabbisogno energetico (Italia) — DATO ITALIANO

- **Link:** <https://dati.terna.it/en/download-center>
- **Contenuto:** dati operativi del gestore della rete di trasmissione elettrica italiana: generazione per fonte (idro, termo, eolico, fotovoltaico, ecc.), fabbisogno, scambi con l'estero. (Terna)
- **Dimensioni:** scaricabili per intervallo temporale; con granularità mensile/oraria si ottengono migliaia di righe gestibili.
- **Variabili:** numeriche (MW/GWh prodotti e richiesti); categoriche (fonte energetica); temporali (data/ora); geografiche (per regione, in alcuni dataset).
- **Visualizzazioni:** mix energetico per fonte (stacked area/bar), serie temporale del fabbisogno, confronto rinnovabili vs fossili.
- **Perché è adatto:** dato italiano tecnico e di attualità (transizione energetica). Richiede selezione dell'intervallo per restare nella dimensione ottimale.

7. UCI Heart Disease (Cleveland) — SALUTE PUBBLICA

- **Link:** <https://archive.ics.uci.edu/dataset/45/heart+disease>
- **Contenuto:** dati clinici di pazienti per la diagnosi di malattia coronarica (database Cleveland, l'unico storicamente usato dai ricercatori ML).
- **Dimensioni:** 303 righe $\times$ 14 attributi (subset standard usato in letteratura sui 76 originali). Licenza CC BY 4.0. (GitHub)
- **Variabili:** numeriche (età, pressione a riposo, colesterolo, frequenza cardiaca max, oldpeak); categoriche (sesso, tipo di dolore toracico, ECG a riposo, angina indotta, thal).
- **Visualizzazioni:** istogrammi per fascia d'età, scatter colesterolo vs frequenza cardiaca, barchart presenza malattia per sesso, heatmap di correlazione.
- **Perché è adatto:** dataset classico, pulito (solo ~6 valori mancanti), ottimo per imparare; piccolo (303 righe), quindi più adatto a una dashboard semplice. Nessuna dimensione temporale o geografica.

8. Stack Overflow Annual Developer Survey — MERCATO DEL LAVORO IT

- **Link:** <https://www.kaggle.com/datasets/stackoverflow/stack-overflow-2023-developers-survey>
- **Contenuto:** risultati del sondaggio annuale agli sviluppatori: linguaggi, strumenti, retribuzioni, esperienza, uso dell'IA.
- **Dimensioni:** l'edizione 2023 ha esattamente 89.184 righe $\times$ 84 colonne (sondaggio condotto 8-19 maggio 2023); l'edizione 2025 conta oltre 49.000 risposte da 177 paesi su 62 domande relative a 314 tecnologie diverse (fonti: survey.stackoverflow.co/2023 e [/2025](https://survey.stackoverflow.co/2025)).
- **Variabili:** numeriche (anni di esperienza, retribuzione annua convertita in USD — (ConvertedCompYearly)); categoriche (linguaggi, paese, tipo di lavoro, formazione); molte colonne multi-valore (es. (LanguageHaveWorkedWith), separate da ";").

- **Visualizzazioni:** barchart linguaggi più usati, boxplot retribuzione per linguaggio/paese, istogramma esperienza, scatter esperienza vs retribuzione.
- **Perché è adatto:** tema IT perfetto per il background informatico; richiede però pulizia delle colonne multi-valore e gestione di molte colonne — leggermente più impegnativo ma molto rilevante per il tuo profilo.

Recommendations

1. **Parti dal CO2 Emission by Vehicles** se vuoi consegnare velocemente: è il miglior compromesso tra semplicità, tema tecnico e ricchezza di visualizzazioni. In 1-2 giorni hai una dashboard con filtri (marca, carburante), scatter, istogrammi e correlazioni.
2. **Aggiungi una dimensione geografica** scegliendo l'Electric Vehicle Population Data: usa `st.map` o `pydeck` per le mappe e dimostra la gestione di dati geografici. Soglia di attenzione: se la dashboard rallenta, campiona le righe o pre-aggrega per contea.
3. **Per la dimensione temporale e i grafici interattivi**, usa il Bike Sharing Dataset: implementa slider sull'ora/mese e grafici animati. È il modo migliore per mostrare interattività temporale.
4. **Se il docente apprezza i dati italiani ufficiali** (probabile, data la richiesta su ISTAT/dati.gov.it), integra gli incidenti stradali di Milano o i dati Terna: rafforzano la rilevanza locale e il carattere "open data istituzionale".
5. **Soglie che cambierebbero la scelta:** se il progetto richiede ML/predizione → CO2 o Heart Disease; se richiede mappe → EV Washington o Formula 1 (circuiti); se richiede serie temporali → Bike Sharing o Terna; se vuoi distinguerti con join multi-tabella → Formula 1; se vuoi rilevanza al tuo settore IT → Stack Overflow. **Evita** dataset oltre ~100.000 righe (US Used Cars ha milioni di record) perché Streamlit ri-esegue lo script a ogni interazione: usa sempre `@st.cache_data` per caricare i dati una sola volta.

Caveats

- I conteggi di righe dei dataset "live" (Electric Vehicle Population, Stack Overflow) variano nel tempo: verifica il numero esatto sulla pagina al momento del download. Per il dataset EV puoi ottenere il conteggio preciso via API: `https://data.wa.gov/resource/f6w7-q2d2.json?\$select=count\(\*\)`.
- Lo "usability score" e la licenza esatta riportata sulla pagina Kaggle del dataset CO2 Emission by Vehicles non sono stati verificabili direttamente (pagina protetta da bot-check); la fonte sottostante è il governo canadese (Open Government Licence - Canada).
- Alcuni dataset Kaggle sulla qualità dell'aria sono dichiaratamente sintetici (es. "Global Air Quality Data 15 Days 50 Cities"): se vuoi dati reali, preferisci ISPRA/ARPA (es. dati.arpae.it per l'Emilia-Romagna) o il World Air Quality Index by City. ([Kaggle](#))
- I dati ICPSR via Università Cattolica/UniData richiedono in genere accesso istituzionale e non sono "liberamente scaricabili" come Kaggle/UCI; il repository istituzionale dell'ateneo (unicatt.digitalcommonsdata.com) e openICPSR offrono sottoinsiemi aperti, ma più orientati a scienze sociali/biomediche che a temi tecnici.

- Il dataset Formula 1 e Stack Overflow sono più complessi (multi-tabella / colonne multi-valore): adatti se vuoi mostrare competenze di data wrangling, meno se cerchi la massima semplicità di consegna.